

Prueba técnica

Se espera que el candidato actúe como “owner” de la solución: que entienda el problema, priorice lo importante, cuide el uso de recursos, optimice el tiempo disponible y comunique claramente lo realizado.

Se permite el uso de herramientas de inteligencia artificial, pero el candidato deberá comprender, justificar y defender lo entregado. Los resultados de estos ejercicios podrían ser insumo para decisiones de producto, arquitectura, estrategia, costos u otras áreas, por lo que se valorará especialmente la claridad conceptual, la trazabilidad de las decisiones y la capacidad de explicar qué se hizo, por qué se hizo y qué conclusiones pueden tomarse.

- La solución deberá subirse a un repositorio de GitHub y compartirse al finalizar la prueba.
- Tiempo de resolución: 48 horas.

Ejercicio 1

Tenemos un producto llamado “SonIA”, un asistente agéntico que ayuda en tareas administrativas de distintos dominios.

El sistema cuenta con un orquestador central y distintos componentes especializados, por ejemplo:

- Subagente calculador: usa un entorno de ejecución de código para tareas de finanzas, fechas y operaciones similares.
- Módulo de análisis de metadata: interpreta metadata de documentos.
- Módulo de gestión de servicio de correo electrónico.
- Módulo de gestión de calendarios.
- Componente resumidor de documentos..

Actualmente estamos teniendo un problema de costos y decidimos evaluar el reemplazo del modelo utilizado por el componente resumidor, ya que detectamos que tiene un impacto importante en el consumo total de tokens del sistema.

Objetivo:

Diseñar e implementar un experimento que permita evaluar tres modelos resumidores candidatos para reemplazar al modelo actual. Para esto se deberá utilizar un dataset que contiene distintos documentos con sus respectivos puntos críticos esperados.

Cada fila contiene:

- ``texto_original``: documento a resumir.

- ``puntos_criticos``: información definida por un experto del dominio que debería estar representada correctamente en un buen resumen. Esta columna se entrega como referencia para la **evaluación** de calidad, **no** como parte del documento a resumir.

Para cada documento del dataset, el sistema deberá:

1. Generar un resumen con cada uno de los tres modelos candidatos.
2. Evaluar automáticamente la calidad de cada resumen utilizando el modelo gpt-5.4 como juez.
3. Comparar la performance alcanzada por los modelos resumidores candidatos.
4. Registrar los resultados de evaluación y el modelo ganador para ese documento.

Consideraciones:

- El componente resumidor utiliza gpt-5.4. Se asume que su performance cumple con los requerimientos de la tarea asignada.
- El dataset general de evaluación tiene 1000 documentos. A los fines de esta prueba, el desarrollador solo tendrá una muestra representativa de 11 documentos para diseñar el experimento, pero deberá ejecutar la solución **únicamente sobre la primera fila**. No obstante, el experimento debe cumplir con todos los requerimientos necesarios para ser ejecutado en los 1000 documentos.
- Solo utilizar modelos del proveedor OpenAI. (se les compartirá una API KEY para realizar la prueba)
- Los modelos a utilizarse como candidatos quedan a criterio del desarrollador.
- Se entrega una prompt base de referencia para el componente resumidor, ya que el foco de este ejercicio no está en el diseño de la prompt de resumen. El candidato podrá utilizarla, modificarla o proponer una variante, siempre que mantenga el objetivo funcional del componente.

Entregables:

- Código para ejecutar el experimento completo (``runner.py``).
- Realizar las pruebas que consideren pertinentes para respaldar sus decisiones en ``experimentos.ipynb``.
- README breve con instrucciones para ejecutar la solución.

Ejercicio 2

SonIA cuenta con un orquestador central que recibe solicitudes de usuarios y debe decidir a qué componente especializado derivar cada petición.

En este ejercicio se trabajará sobre un clasificador semántico encargado de identificar cuál es el primer módulo que debería intervenir para resolver correctamente la solicitud del usuario.

Los módulos posibles son:

- CALCULADORA
- METADATA
- MAILS
- CALENDARIO
- RESUMIDOR

Se entrega un dataset con predicciones generadas por un primer modelo clasificador.

Cada fila contiene:

- texto_usuario: solicitud realizada por el usuario.
- categoria_esperada: módulo correcto al que debería derivarse inicialmente la petición.
- categoria_predicha: módulo predicho por el clasificador evaluado.
- multilabel_referencia: proviene de la planificación de ruta.
- explicacion_referencia: explica el contexto del ejemplo.

Objetivo

Evaluar el comportamiento del clasificador a partir de las predicciones provistas y elaborar un informe sobre su desempeño.

Consideraciones

Algunas solicitudes pueden involucrar más de una acción. Sin embargo, para este ejercicio se evalúa **únicamente** el primer módulo que debería intervenir.

Por ejemplo, si una solicitud requiere generar información antes de enviarla por mail, la categoría esperada será el módulo que debe producir primero esa información.

Las columnas multilabel_referencia y explicacion_referencia se incluyen como contexto adicional para comprender mejor cada ejemplo, pero la evaluación debe realizarse sobre categoria_esperada y categoria_predicha.

No se espera entrenar un modelo nuevo ni modificar las predicciones provistas. El foco del ejercicio está en analizar el comportamiento del clasificador.

Entregables

El candidato deberá entregar:

- analisis_clasificador.ipynb

El notebook deberá incluir el análisis realizado, el código utilizado y una conclusión final fundamentada en los resultados obtenidos.